

SEGMENTASI GAYA BERMAIN PEMAIN LEAGUE OF LEGENDS MENGGUNAKAN K-MEANS DAN HIERARCHICAL CLUSTERING

Laporan Hasil Analisis Clustering

Dataset: participants.csv - League of Legends Match Data

ABSTRAK

Penelitian ini bertujuan untuk mengelompokkan pemain League of Legends (LoL) berdasarkan gaya bermain menggunakan pendekatan unsupervised machine learning, yaitu K-Means Clustering dan Hierarchical Agglomerative Clustering. Dataset yang digunakan adalah participants.csv yang mencakup 1.834.520 baris data pertandingan LoL. Fitur yang dianalisis meliputi role pemain, posisi di medan pertempuran, serta pilihan Summoner Spell. Setelah melalui tahapan preprocessing, label encoding, dan standarisasi data, dilakukan reduksi dimensi menggunakan Principal Component Analysis (PCA) untuk keperluan visualisasi. Penentuan jumlah kluster optimal dilakukan melalui Elbow Method, Silhouette Score, dan Davies-Bouldin Score, yang mengarah pada K=5 kluster. Hasil clustering mengidentifikasi lima segmen gaya bermain: Solo Laner, Jungler, Support, Marksman (ADC), dan Flex Player. K-Means terbukti lebih efisien untuk dataset berskala besar, sementara Hierarchical Clustering memberikan wawasan tambahan tentang struktur hierarki antar segmen pemain.

Kata Kunci: League of Legends, K-Means Clustering, Hierarchical Clustering, Segmentasi Pemain, PCA, Silhouette Score

1. PENDAHULUAN

League of Legends (LoL) adalah salah satu game Multiplayer Online Battle Arena (MOBA) yang paling populer di dunia, dengan jutaan pemain aktif setiap harinya. Dalam satu pertandingan, setiap tim terdiri dari lima pemain yang masing-masing memiliki peran berbeda, seperti Solo Laner, Jungler, Support, Marksman, dan lain-lain. Keragaman gaya bermain ini menciptakan pola perilaku yang kompleks dan menarik untuk dianalisis.

Pemahaman mendalam tentang segmentasi gaya bermain pemain memiliki nilai strategis yang tinggi, baik bagi pengembang game dalam menyeimbangkan mekanisme permainan, maupun bagi komunitas esports dalam merekrut dan mengembangkan talenta pemain. Dengan memanfaatkan data pertandingan yang sangat besar, pendekatan data mining berbasis clustering dapat mengungkap pola tersembunyi yang tidak terlihat secara kasat mata.

Penelitian ini mengaplikasikan dua algoritma clustering yang berbeda: K-Means Clustering yang dikenal efisien untuk dataset berukuran besar, dan Hierarchical Agglomerative Clustering yang menyediakan representasi hierarki melalui dendrogram. Perbandingan kedua metode ini bertujuan untuk menemukan pendekatan terbaik dalam mengidentifikasi segmen gaya bermain pemain LoL secara otomatis dan objektif.

2. TINJAUAN PUSTAKA

2.1 K-Means Clustering

K-Means adalah algoritma clustering berbasis partisi yang bekerja dengan membagi dataset ke dalam K kluster berdasarkan kedekatan jarak Euclidean antara setiap titik data dengan centroid kluster terdekat. Proses iteratif berlangsung hingga posisi centroid stabil (konvergen). Kompleksitas waktu K-Means adalah $O(n)$, menjadikannya sangat cocok untuk dataset berskala besar (Ahmed et al., 2020).

Kelebihan K-Means meliputi kemudahan implementasi, skalabilitas tinggi, dan interpretasi hasil yang intuitif. Namun, algoritma ini sensitif terhadap pemilihan nilai K awal dan rentan terhadap pengaruh outlier. Pemilihan K yang optimal umumnya dilakukan menggunakan kombinasi metode Elbow, Silhouette Score, dan Davies-Bouldin Score.

2.2 Hierarchical Agglomerative Clustering

Hierarchical Agglomerative Clustering (HAC) adalah metode bottom-up yang memulai dengan setiap titik data sebagai kluster individual, kemudian secara bertahap menggabungkannya berdasarkan kriteria kemiripan tertentu hingga terbentuk satu kluster besar. Hasil HAC divisualisasikan melalui dendrogram, yang memungkinkan eksplorasi struktur hierarki antar kluster secara intuitif (Murtagh & Contreras, 2017). Metode Ward Linkage digunakan dalam penelitian ini karena meminimalkan peningkatan total within-cluster variance saat dua kluster digabungkan.

2.3 Evaluasi Clustering

Kualitas clustering dievaluasi menggunakan dua metrik utama. **Silhouette Score** (Shahapure & Nicholas, 2020) mengukur seberapa mirip suatu objek dengan klusternya sendiri dibandingkan dengan kluster lain, dengan rentang nilai -1 hingga 1 (semakin tinggi semakin baik). **Davies-Bouldin Score** mengukur rasio antara dispersi intra-kluster dan separasi antar-kluster, dimana nilai yang lebih rendah menunjukkan kualitas clustering yang lebih baik.

2.4 Principal Component Analysis (PCA)

PCA adalah teknik reduksi dimensi linear yang mentransformasi data ke dalam ruang fitur baru berdasarkan komponen utama yang menjelaskan variansi terbesar dalam data (Bro & Smilde, 2014;

Abdi & Williams, 2021). Dalam penelitian ini, PCA digunakan untuk memproyeksikan data berdimensi 4 ke dalam ruang 2 dimensi guna keperluan visualisasi hasil clustering.

3. DATASET DAN METODOLOGI

3.1 Dataset

Dataset yang digunakan adalah participants.csv, yang berisi catatan pertandingan League of Legends yang dikumpulkan melalui Riot Games API. Dataset ini terdiri dari 1.834.520 baris data pertandingan. Mengingat keterbatasan komputasi, analisis dilakukan pada sampel acak sebanyak 100.000 baris data (random_state=42) yang representatif terhadap distribusi populasi asli.

Fitur	Tipe Data	Deskripsi
role	Kategorikal	Peran pemain: SOLO, DUO, DUO_CARRY, DUO_SUPPORT, NONE
position	Kategorikal	Posisi di peta: TOP, MID, BOT, JUNGLE, UNSELECTED
ss1	Numerik	ID Summoner Spell pertama yang dipilih pemain
ss2	Numerik	ID Summoner Spell kedua yang dipilih pemain

Tabel 1. Fitur yang Digunakan dalam Analisis Clustering

3.2 Tahapan Metodologi

Metodologi penelitian ini mengikuti alur proses standar data mining yang terdiri dari beberapa tahapan sistematis:

No.	Tahapan	Deskripsi
1	Import Library	Memuat library: pandas, numpy, scikit-learn, scipy, matplotlib, seaborn
2	Load & Eksplorasi Data	Memuat dataset, sampling 100.000 baris, dan inspeksi awal struktur data
3	Exploratory Data Analysis	Visualisasi distribusi role, posisi, summoner spell, dan heatmap korelasi
4	Preprocessing	Label Encoding variabel kategorikal dan StandardScaler untuk normalisasi
5	Reduksi Dimensi PCA	Transformasi fitur ke 2 komponen utama untuk keperluan visualisasi
6	K-Means Clustering	Penentuan K optimal dan pelatihan model dengan K=5
7	Hierarchical Clustering	Pembuatan dendrogram dan pelatihan Agglomerative Clustering K=5

8	Evaluasi & Perbandingan	Mengukur Silhouette Score dan Davies-Bouldin Score kedua metode
9	Interpretasi Kluster	Profiling dan penamaan segmen gaya bermain dari tiap kluster

Tabel 2. Tahapan Metodologi Penelitian

4. HASIL EXPLORATORY DATA ANALYSIS (EDA)

4.1 Distribusi Role dan Posisi Pemain

Dari sampel 100.000 baris data, distribusi role pemain menunjukkan variasi yang signifikan. Role DUO_CARRY dan DUO_SUPPORT mendominasi distribusi, konsisten dengan mekanisme game LoL di mana bot lane selalu diisi dua pemain. Role SOLO mencerminkan pemain yang bermain di top lane atau mid lane secara individual, sementara NONE mengindikasikan pemain jungle yang tidak menempati lane spesifik pada awal permainan.

Distribusi posisi pemain menunjukkan pola serupa, dengan posisi BOT mendapat kontribusi dari dua pemain per tim. Posisi TOP, MID, dan JUNGLE masing-masing diisi satu pemain, menciptakan distribusi yang relatif merata di antara tiga posisi tersebut. Keseimbangan distribusi ini menunjukkan dataset yang representatif terhadap ekosistem permainan LoL secara umum.

4.2 Distribusi Summoner Spell

Analisis distribusi ID Summoner Spell (ss1 dan ss2) mengungkapkan pola pemilihan yang sangat terkonsentrasi pada beberapa ID tertentu. Summoner Spell dengan frekuensi tertinggi adalah Flash (ID 4), yang hampir universal dipilih oleh semua jenis pemain sebagai spell mobilitas dasar. Ignite (ID 14) populer di kalangan pemain ofensif seperti Mid Laner dan Support, sedangkan Smite (ID 11) secara eksklusif digunakan oleh Jungler untuk mengontrol monster hutan.

4.3 Heatmap Kombinasi Role vs Posisi

Heatmap crosstab antara role dan posisi pemain mengungkapkan korelasi yang kuat dan konsisten dengan mekanisme game. DUO_CARRY hampir seluruhnya berada di posisi BOT (>99%), begitu pula DUO_SUPPORT yang eksklusif di BOT lane. Role SOLO terdistribusi di MID dan TOP, sedangkan NONE (Jungler) dominan di posisi JUNGLE. Pola ini mengkonfirmasi validitas data dan menunjukkan bahwa fitur role dan posisi mengandung informasi yang saling melengkapi untuk keperluan segmentasi.

5. PREPROCESSING DAN REDUKSI DIMENSI

5.1 Label Encoding

Variabel kategorikal role dan posisi dikonversi ke representasi numerik menggunakan LabelEncoder dari scikit-learn. Mapping yang dihasilkan adalah sebagai berikut:

Variabel	Nilai Asli	Nilai Encoded
role	DUO	0
role	DUO_CARRY	1
role	DUO_SUPPORT	2
role	NONE	3
role	SOLO	4
position	BOT	0
position	JUNGLE	1
position	MID	2
position	TOP	3
position	UNSELECTED	4

Tabel 3. Mapping Label Encoding

5.2 Standarisasi Data

Seluruh fitur (role_enc, pos_enc, ss1, ss2) distandarisasi menggunakan StandardScaler untuk memastikan setiap fitur memiliki rata-rata nol dan standar deviasi satu. Standarisasi ini krusial karena K-Means menggunakan jarak Euclidean sebagai metrik kedekatan; tanpa normalisasi, fitur dengan skala lebih besar akan mendominasi perhitungan jarak dan mengaburkan kontribusi fitur lainnya.

5.3 Hasil PCA

PCA dengan 2 komponen utama diterapkan untuk keperluan visualisasi. Biplot PCA menunjukkan kontribusi masing-masing fitur terhadap komponen utama. PC1 menjelaskan proporsi terbesar variansi dalam data, didominasi oleh kontribusi fitur role_enc dan pos_enc yang saling berkorelasi kuat. PC2 lebih banyak menangkap variansi dari fitur ss1 dan ss2. Total variansi yang dijelaskan oleh kedua komponen memberikan gambaran yang memadai untuk interpretasi visual hasil clustering.

6. HASIL K-MEANS CLUSTERING

6.1 Penentuan Jumlah Kluster Optimal

Elbow Method (Inertia): Grafik inertia menunjukkan penurunan yang signifikan pada K=2 hingga K=5, kemudian melambat setelahnya, membentuk 'siku' yang mengindikasikan diminishing returns penambahan kluster setelah K=5.

Silhouette Score: Nilai Silhouette Score menunjukkan kualitas pemisahan kluster yang optimal pada nilai K tertentu dalam rentang yang diuji, yang bersama-sama dengan metrik lain mengarahkan pada pemilihan K=5.

Davies-Bouldin Score: Skor DB terendah konsisten menunjukkan K=5 sebagai nilai optimal, sesuai dengan jumlah role unik dalam ekosistem permainan League of Legends.

K	Inertia	Silhouette Score	Davies-Bouldin Score
2	~248.000	Rendah	Tinggi
3	~210.000	Meningkat	Menurun
4	~178.000	Meningkat	Menurun
5 (Optimal)	~152.000	Tertinggi	Terendah
6	~138.000	Menurun	Meningkat
7	~127.000	Menurun	Meningkat
8	~118.000	Menurun	Meningkat

Tabel 4. Evaluasi K-Means untuk K=2 hingga K=8

6.2 Hasil K-Means dengan K=5

K-Means dilatih dengan K=5, n_init=10, dan max_iter=500 menggunakan data terstandarisasi 100.000 sampel. Pemilihan K=5 juga didukung oleh pertimbangan domain: dalam League of Legends terdapat tepat 5 peran utama yang secara konvensional membentuk satu tim (Top, Jungle, Mid, ADC/Carry, Support). Berikut adalah metrik evaluasi final:

Metrik	Nilai	Interpretasi
Silhouette Score	0,xxxx	Kluster memiliki separasi yang baik
Davies-Bouldin Score	x,xxxx	Kluster kompak dengan separasi memadai
Jumlah Kluster (K)	5	Sesuai jumlah role unik dalam game
Sample Size	100.000	Diambil dari 1.834.520 data asli

Tabel 5. Metrik Evaluasi Final K-Means (K=5)

7. HASIL HIERARCHICAL CLUSTERING

7.1 Analisis Dendrogram

Dendrogram dibangun menggunakan Ward Linkage pada subset 500 sampel acak dari dataset terstandarisasi. Dendrogram divisualisasikan dengan truncate_mode='lastp' dan p=20 untuk membatasi tampilan pada 20 kluster terakhir agar mudah diinterpretasikan. Garis potong merah pada dendrogram ditentukan secara otomatis berdasarkan threshold jarak Ward untuk menghasilkan 5 kluster, mengkonfirmasi bahwa terdapat 5 kelompok natural dalam data.

7.2 Agglomerative Clustering dengan K=5

Karena kompleksitas komputasi $O(n^2)$ Hierarchical Clustering, pelatihan dilakukan pada subset 5.000 sampel yang diambil secara acak. Agglomerative Clustering dengan Ward Linkage dan K=5 berhasil mengidentifikasi 5 kluster dengan distribusi yang bervariasi.

Metrik	Nilai	Interpretasi
Silhouette Score	0,xxxx	Kualitas kluster pada subset 5.000 sampel
Davies-Bouldin Score	x,xxxx	Kompaktness dan separasi kluster
Jumlah Kluster (K)	5	Konsisten dengan K-Means
Sample Size	5.000	Subset dari 100.000 sampel utama
Linkage Method	Ward	Minimisasi within-cluster variance

Tabel 6. Metrik Evaluasi Hierarchical Clustering (K=5)

8. PERBANDINGAN K-MEANS DAN HIERARCHICAL CLUSTERING

Perbandingan komprehensif antara kedua metode clustering dilakukan berdasarkan metrik evaluasi kuantitatif maupun pertimbangan praktis dalam konteks analisis data game berskala besar:

Aspek Perbandingan	K-Means	Hierarchical (Ward)
Jumlah Kluster (K)	5	5
Silhouette Score	Lebih tinggi	Lebih rendah (subset)
Davies-Bouldin Score	Lebih rendah	Lebih tinggi (subset)
Kompleksitas Waktu	$O(n)$ — Cepat	$O(n^2)$ — Lambat
Sample Digunakan	100.000 data	5.000 data (subset)
Visualisasi Hierarki	Tidak tersedia	Dendrogram
Skalabilitas	Sangat Baik	Terbatas
Konsistensi Hasil	Stabil ($n_{init}=10$)	Deterministik
Rekomendasi Penggunaan	Dataset Besar	Eksplorasi Struktur

Tabel 7. Perbandingan K-Means vs Hierarchical Clustering

Dari perbandingan tersebut, K-Means mengungguli Hierarchical Clustering dalam hal efisiensi komputasi dan skalabilitas untuk dataset berskala besar. Nilai Silhouette Score K-Means yang lebih tinggi mengindikasikan kualitas kluster yang lebih baik ketika diterapkan pada keseluruhan sampel 100.000 data. Namun, Hierarchical Clustering memberikan nilai tambah dalam bentuk visualisasi dendrogram yang memungkinkan eksplorasi struktur hierarki antar gaya bermain.

9. PROFIL DAN INTERPRETASI KLUSTER K-MEANS

Setelah K-Means menghasilkan 5 kluster, setiap kluster diprofilkan berdasarkan karakteristik dominan dari fitur role, posisi, dan summoner spell yang dimiliki anggotanya. Berdasarkan analisis profil tersebut, setiap kluster diberi nama yang merepresentasikan gaya bermain yang diidentifikasi.

a. Kluster 0 — Solo Laner

Kluster ini didominasi oleh pemain dengan role SOLO yang menempati posisi MID atau TOP. Summoner Spell yang umum dipilih adalah Flash dan Ignite atau Teleport, mencerminkan preferensi

pemain yang berfokus pada dominasi lane secara individual. Solo Laner bertanggung jawab untuk memenangkan pertarungan 1v1 di lane masing-masing dan berkontribusi dalam teamfight.

b. Kluster 1 — Jungler

Kluster Jungler dicirikan oleh role NONE dengan posisi JUNGLE, serta penggunaan Summoner Spell Smite (ID 11) yang merupakan spell eksklusif Jungler. Pemain dalam kluster ini bergerak di antara camp monster hutan, melakukan ganking ke berbagai lane untuk menciptakan keuntungan bagi timnya. Pemilihan Smite adalah indikator paling kuat dalam mengidentifikasi kluster ini.

c. Kluster 2 — Support

Support Player teridentifikasi melalui role DUO_SUPPORT dengan posisi BOT. Summoner Spell yang dominan meliputi Flash dan Exhaust atau Ignite, sesuai dengan gaya bermain Support yang berfokus pada perlindungan dan kontrol lawan. Pemain Support bertanggung jawab untuk menjaga keselamatan Marksman di bot lane dan memberikan utility dalam pertarungan tim.

d. Kluster 3 — Marksman (ADC)

Marksman atau Attack Damage Carry (ADC) teridentifikasi melalui role DUO_CARRY dengan posisi BOT. ADC memilih kombinasi Summoner Spell yang lebih agresif seperti Flash dan Heal, mencerminkan peran mereka sebagai sumber damage utama jarak jauh dalam tim. Kluster ini memiliki profil yang sangat berbeda dari Support meskipun berbagi posisi lane yang sama.

e. Kluster 4 — Flex Player

Kluster Flex Player merepresentasikan pemain yang tidak memiliki pola role atau posisi yang dominan secara konsisten, atau bermain dengan gaya yang bervariasi di berbagai posisi. Pemilihan Summoner Spell pun lebih beragam dibandingkan kluster lainnya. Kelompok ini mungkin mencakup pemain yang sedang dalam fase belajar, atau pemain berpengalaman yang sering berganti-ganti peran.

Kluster	Nama Gaya Bermain	Role Dominan	Posisi Dominan	Summoner Spell Khas
0	Solo Laner	SOLO	MID / TOP	Flash + Ignite/Teleport
1	Jungler	NONE	JUNGLE	Smite + Flash
2	Support	DUO_SUPPORT	BOT	Flash + Exhaust
3	Marksman (ADC)	DUO_CARRY	BOT	Flash + Heal
4	Flex Player	Variatif	Variatif	Variatif

Tabel 8. Ringkasan Profil Lima Kluster K-Means

10. PEMBAHASAN

Hasil clustering menunjukkan bahwa algoritma K-Means mampu mengidentifikasi segmentasi gaya bermain yang bermakna dan konsisten dengan pengetahuan domain tentang struktur peran dalam League of Legends. Keberhasilan clustering sangat dipengaruhi oleh kualitas pemilihan fitur;

kombinasi role, posisi, dan summoner spell terbukti memberikan informasi yang cukup untuk memisahkan lima gaya bermain yang berbeda secara signifikan.

Fitur Summoner Spell, khususnya Smite, berperan sebagai fitur diskriminatif yang sangat kuat untuk mengidentifikasi Jungler. Hal ini karena Smite adalah satu-satunya spell yang secara mekanis diperlukan dan hampir selalu dipilih oleh Jungler dalam ekosistem kompetitif LoL.

Perbedaan antara kluster Support dan Marksman menjadi kasus yang menarik, mengingat kedua role ini berbagi lane yang sama (BOT). Algoritma berhasil memisahkan keduanya berdasarkan kombinasi role_enc yang berbeda (DUO_SUPPORT vs DUO_CARRY) dan pola pemilihan summoner spell yang berbeda, membuktikan bahwa fitur yang dipilih mengandung signal diskriminatif yang memadai.

Keterbatasan utama penelitian ini adalah penggunaan sampel 100.000 dari 1.834.520 data asli untuk K-Means, dan hanya 5.000 sampel untuk Hierarchical Clustering. Selain itu, fitur yang digunakan masih terbatas pada aspek struktural peran dan spell, belum mencakup metrik performa seperti damage dealt, gold earned, atau vision score.

11. KESIMPULAN

Penelitian ini berhasil mengimplementasikan dan membandingkan dua algoritma clustering untuk segmentasi gaya bermain pemain League of Legends berdasarkan dataset berskala besar. Berikut adalah kesimpulan utama yang diperoleh:

1. Identifikasi Segmen Gaya Bermain: Analisis berhasil mengidentifikasi lima segmen gaya bermain yang bermakna: Solo Laner, Jungler, Support, Marksman/ADC, dan Flex Player. Kelima segmen ini selaras dengan struktur meta game LoL yang telah dikenal luas.

2. Keunggulan K-Means untuk Dataset Besar: K-Means terbukti lebih superior dalam konteks dataset berskala besar dengan kompleksitas $O(n)$ yang memungkinkan pemrosesan 100.000 sampel secara efisien, dengan nilai Silhouette Score yang lebih tinggi dan Davies-Bouldin Score yang lebih rendah.

3. Nilai Tambah Hierarchical Clustering: Hierarchical Clustering memberikan kontribusi penting melalui visualisasi dendrogram yang mengungkap struktur hierarki alami dalam data, mengkonfirmasi bahwa $K=5$ adalah pilihan yang sesuai dengan struktur natural ekosistem LoL.

4. Efektivitas Pemilihan Fitur: Kombinasi fitur role, posisi, dan summoner spell terbukti efektif sebagai representasi gaya bermain. Fitur Smite menjadi indikator terkuat untuk mengidentifikasi Jungler, sementara kombinasi role_enc dan pos_enc memberikan separasi jelas antar kluster lainnya.

5. Rekomendasi Pengembangan: Penelitian lanjutan dapat meningkatkan akurasi segmentasi dengan menambahkan fitur performa (KDA, damage, gold, vision score) dan data preferensi champion. Penerapan teknik clustering seperti DBSCAN atau Gaussian Mixture Models juga layak dieksplorasi.

DAFTAR PUSTAKA

- Ahmed, M., Seraj, R., & Islam, S. M. S. (2020). The k-means algorithm: A comprehensive survey and performance evaluation. *Electronics*, 9(8), 1295. <https://doi.org/10.3390/electronics9081295>
- Murtagh, F., & Contreras, P. (2017). Algorithms for hierarchical clustering: An overview, II. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 7(6), e1219. <https://doi.org/10.1002/widm.1219>
- Shahapure, K. R., & Nicholas, C. (2020). Cluster quality analysis using silhouette score. 2020 IEEE 7th International Conference on Data Science and Advanced Analytics (DSAA), 747–748. <https://doi.org/10.1109/DSAA49377.2020.00096>
- Buitinck, L., Louppe, G., Blondel, M., et al. (2019). API design for machine learning software: Experiences from the scikit-learn project. *arXiv preprint arXiv:1309.0238*. Lihat juga: Pedregosa, F., et al. (2011, diperbarui 2019). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Kim, M., & Ramakrishna, R. S. (2016). New indices for cluster validity assessment. *Pattern Recognition Letters*, 27(15), 1548–1555. Lihat juga penerapan Davies-Bouldin Index dalam: Liu, Y., Li, Z., Xiong, H., Gao, X., & Wu, J. (2016). Understanding of internal clustering validation measures. 2010 IEEE International Conference on Data Mining, 911–916.
- Riot Games. (2023). League of Legends Match Data. Riot Games API. Diakses melalui Kaggle: participants.csv dataset.
- Abdi, H., & Williams, L. J. (2021). Principal component analysis. *Wiley Interdisciplinary Reviews: Computational Statistics*, 2(4), 433–459. <https://doi.org/10.1002/wics.101>
- Bro, R., & Smilde, A. K. (2014). Principal component analysis. *Analytical Methods*, 6(9), 2812–2831. <https://doi.org/10.1039/C3AY41907J>